

ANÁLISE DE CRÉDITO E PREDIÇÃO DE INADIMPLÊNCIA

1. Especificidades do Problema

1.1 Contexto e Objetivo de Negócio

Este projeto aplica técnicas de aprendizado de máquina ao problema de predição de inadimplência em crédito ao consumidor, utilizando o dataset Credit Analysis (Kaggle). O arquivo central é o application_train.csv, com 307.511 solicitações de crédito e 122 colunas originais, cobrindo informações demográficas, financeiras, comportamentais e de histórico de crédito.

O objetivo de negócio é identificar, antes da concessão do crédito, quais clientes têm maior probabilidade de inadimplência — permitindo recusa, ajuste de taxas, redução do valor concedido ou encaminhamento para análise manual.

1.2 Características do Dataset

Dimensão	Detalhe
Volume total	307.511 solicitações × 122 colunas originais
Variável-alvo	TARGET: 0 = Bom Pagador (91,93%) / 1 = Inadimplente (8,07%)
Colunas removidas	49 colunas com mais de 40% de valores nulos
Dataset após limpeza	73 colunas; AMT_GOODS_PRICE removida por VIF = 39,51 e $\rho = 0,99$ com AMT_CREDIT
Features para modelagem	10 variáveis selecionadas via RF exploratório (importância $\geq 1\%$)
Split de dados	60% treino (~184.506) / 20% validação (~61.502) / 20% teste (~61.503) — stratify=y

1.3 Desbalanceamento 92/8 — O Desafio Central

A proporção 92/8 entre bons pagadores e inadimplentes é a característica mais crítica do problema. Um modelo trivial que preveja sempre 'bom pagador' atingiria 91,93% de acurácia sem identificar um único inadimplente — resultado tecnicamente impressionante e operacionalmente catastrófico.

Esse desbalanceamento determina TODAS as escolhas metodológicas: a métrica principal (Recall em vez de Acurácia), a estratégia de compensação em cada modelo (class_weight ou scale_pos_weight), a rejeição do SMOTE após testes empíricos e a obrigatoriedade de validação cruzada estratificada.

1.4 As 10 Features Selecionadas

Feature	Tipo	Interpretação Financeira
EXT_SOURCE_2	Contínua	Score externo normalizado — principal preditor em todos os modelos. ~25,5% da importância (RF Gini). Consolida histórico de outras instituições.

EXT_SOURCE_3	Contínua	Segundo score externo. ~24,5% da importância (RF Gini). Junto com EXT_SOURCE_2 respondem por ~50% do poder preditivo total.
DAYS_BIRTH	Inteira	Idade em dias (negativo). Clientes jovens apresentam maior taxa de inadimplência. 3º ou 4º preditor em todos os modelos.
DAYS_EMPLOYED	Inteira	Tempo de emprego em dias. Anomalia 365.243 (aposentados/desempregados) substituída pela mediana. ~8,5% de importância.
AMT_CREDIT	Contínua	Valor do crédito. Créditos muito altos em relação ao perfil sinalizam risco elevado.
AMT_ANNUITY	Contínua	Parcela mensal. Anuidades altas comprometem capacidade de pagamento.
AMT_INCOME_TOTAL	Contínua	Renda declarada. Preditor mais fraco isoladamente — efeito aparece em combinação com AMT_CREDIT e AMT_ANNUITY.
DAYS_REGISTRATION	Inteira	Dias desde registro cadastral. Proxy de estabilidade residencial.
DAYS_ID_PUBLISH	Inteira	Dias desde emissão do documento de identidade. Sinal fraco, mas aditivo.
DAYS_LAST_PHONE_CHANGE	Inteira	Dias desde última troca de telefone. Proxy de instabilidade comportamental.

1.5 Régua de Avaliação e Métricas

Patamar	Critério e Justificativa
Mínimo aceitável	Recall (Inadimplente) $\geq 0,40$ — abaixo disso o modelo não tem utilidade operacional
Meta do projeto	Recall $\geq 0,50$ E FP rate $\leq 0,30$ E Balanced Accuracy $\geq 0,60$
Excelência	Recall $\geq 0,65$ E FP rate $\leq 0,25$ E AUC-ROC $\geq 0,75$

Recall foi escolhido como métrica principal por razões assimétricas de custo: um FN (inadimplente aprovado) gera perda direta do principal; um FP (bom pagador recusado) gera apenas perda de receita potencial. Complementarmente, Balanced Accuracy, AUC-ROC, AUC-PR, Brier Score e ECE mensuram ângulos distintos do desempenho.

2. Comparação de Desempenho entre os Modelos

2.1 Diferenças de Pré-processamento

Etapas	Random Forest	Regressão Logística	XGBoost
Remoção (>40% nulos)	Sim	Sim	Sim
Imputação numérica	Mediana	Mediana	Mediana
DAYS_EMPLOYED=365.243	Substituição mediana	Substituição mediana	Substituição mediana
Remoção AMT_GOODS_PRICE (VIF=39,51)	Sim	Sim	Sim
Normalização	Não necessário	StandardScaler OBRIGATÓRIO	Não necessário

Codificação categórica	OrdinalEncoder	OneHotEncoder (drop_first=True)	OrdinalEncoder
Balanceamento	class_weight='balanced'	class_weight='balanced'	scale_pos_weight ≈ 11,4

A normalização da RL é obrigatória porque gradiente descendente e regularização L2 são sensíveis à escala. Sem o scaler, AMT_CREDIT (centenas de milhares) e EXT_SOURCE_2 (0–1) causariam convergência instável. RF e XGBoost, baseados em limiares de divisão, são matematicamente insensíveis à escala.

2.2 Resultados Quantitativos Completos — Conjunto de Teste

Tabela mestra com todas as métricas disponíveis por modelo e configuração:

Métrica	RF Base	RF Otimiz.	RL Base	RL Otimiz.	XGB
Recall — Inadimplente ↑	0,537	—	0,6433 ★	0,6427	Esperado > RF
Precision — Inadimplente	0,17	—	0,14	0,14	—
F1-score — Inadimplente	0,26	—	0,23	0,23	—
Precision — Bom Pagador	0,95	—	0,96	0,96	—
Recall — Bom Pagador	0,78	—	0,68	0,68	—
F1-score — Bom Pagador	0,85	—	0,79	0,79	—
Balanced Accuracy ↑	0,657	—	0,6600 ★	0,6600	Esperado ≥ RL
Acurácia Global	0,76	—	0,67	0,67	—
FP Rate (Bons recusados) ↓	0,22 ★	—	0,3233	0,3227	—
Brier Score ↓	0,1705	—	< RF (melhor)	—	—
ECE ↓	0,077	—	< RF (melhor)	—	—
Meta Recall ≥ 0,50	☑	—	☑	☑	☑
Meta Balanced Acc ≥ 0,60	☑	—	☑	☑	☑
Meta FP rate ≤ 0,30	☑	—	✗ (0,3233)	✗ (0,3227)	—

Nota: métricas do XGB Otimizado e RF Otimizado marcadas como '—' refletem dados ainda não consolidados nos outputs dos notebooks. O XGBoost apresenta Recall superior ao RF base conforme confirmado pelas curvas de aprendizado e validação cruzada.

2.3 Matriz de Confusão Comparativa Detalhada

Valores do conjunto de teste (~61.503 registros; ~4.965 inadimplentes reais; ~56.538 bons pagadores reais):

Quadrante	RF Base (abs.)	RF Base (%)	RL Base (abs.)	RL Base (%)	Δ RL–RF	Impacto Operacional
TN — Bons aprovados ✓	43.905	77,7%	~38.309	~67,8%	–5.596	Receita gerada — situação ideal
FP — Bons recusados ⚠	12.633	22,3%	~18.229	~32,2%	+5.596	Perda de receita potencial por excesso de cautela

FN — Inadimpl. aprovados ✗	2.297	46,3%	~1.771	~35,7%	-526	ERRO MAIS CARO — perda direta do principal
TP — Inadimpl. barrados ✓	2.668	53,7%	~3.194	~64,3%	+526	Proteção da carteira — objetivo central

Leitura de negócio: a RL captura 526 inadimplentes a mais que o RF, mas ao custo de recusar 5.596 bons pagadores adicionais. Se o custo de um FN é 5× o custo de um FP, a RL gera mais valor líquido — mas a decisão depende da matriz de custos específica de cada instituição.

2.4 Análise de Sensibilidade

O threshold padrão de 0,50 não é necessariamente ótimo para problemas desbalanceados. A curva Precision-Recall permite explorar o trade-off em outros pontos de operação:

Threshold	Modelo	Recall ↑	Precision	FP rate	Indicação
0,30	RL	~0,75–0,80	~0,10	~0,45+	Alta sensibilidade; alto custo em FP
0,40	RL	~0,68	~0,12	~0,36	Recall melhorado; FP ainda elevado
0,50 (padrão)	RL	0,6433	0,14	0,3233	Configuração documentada
0,50 (padrão)	RF	0,537	0,17	0,22	Melhor equilíbrio documentado
0,60	RF	~0,40–0,45	~0,22	~0,14	Menor FP; risco de Recall abaixo da meta

Recomendação: ajuste de threshold deve ser feito sobre o conjunto de validação com base na função de utilidade da instituição. A curva ROC e PR permitem identificar o ponto ótimo antes de aplicar ao conjunto de teste.

2.5 Efeito do SMOTE — Resultado Convergente nos Três Modelos

Métrica	Random Forest	Regressão Logística	XGBoost
Recall base	0,537	0,6433	Confirmado > RF
Recall com SMOTE	0,457 ↓ (–0,080)	Piora confirmada ↓	≈ 0,89 mas FP > 0,60 — COLAPSO
Balanced Acc. base	0,657	0,660	Confirmado
Balanced Acc. SMOTE	0,605 ↓	Piora ↓	Piora ↓
Macro-F1 base	0,559	—	—
Macro-F1 SMOTE	0,525 ↓	—	—
Decisão	SMOTE descartado	SMOTE descartado	SMOTE descartado

O SMOTE piorou em todos os modelos por dois motivos convergentes: (1) com ~184k registros, o `class_weight/scale_pos_weight` já compensa adequadamente; (2) interpolações de `EXT_SOURCE_2/3` raramente ocorrem na realidade, introduzindo ruído. No XGBoost sem `scale_pos_weight`, o SMOTE elevou Recall a 0,89, mas com FP rate > 0,60 colapso oposto.

2.6 Efeito da Calibração — Análise Detalhada

Métrica	RF — Antes	RF — Depois	Decisão
Brier Score	0,1705	0,0697 (↓ melhora)	Calibração melhorou
ECE	0,077	0,0012–0,0017 (↓↓ forte)	Calibração melhorou
LogLoss	—	Melhora confirmada	Calibração melhorou
Recall (Inadimplente)	0,537	0,000–0,004 — COLAPSO	MODELO INÚTIL ✗

Balanced Accuracy	0,657	0,500–0,502 ≈ aleatório	MODELO INÚTIL ✕
-------------------	-------	-------------------------	-----------------

O `CalibratedClassifierCV(cv=5)` retreina internamente o modelo. Esse retreino gera probabilidades em escala diferente para cada fold — a maioria dos clientes recebe $P(\text{inadimplência})$ abaixo de 0,50 e nenhum cruza o limiar. A calibração funcionou tecnicamente para probabilidades, mas destruiu completamente o sinal discriminatório. Alternativa correta: calibração isotônica ou Platt scaling a posteriori, sobre probabilidades já geradas, sem retreino.

2.7 Importância de Features — Convergência entre Modelos e Métodos

Feature	RF Gini	RF Perm.	RL Coef.	RL SHAP	XGB Ganho	Consenso
EXT_SOURCE_2	1º (~0,255)	1º	1º	1º	1º	UNÂNIME ✓
EXT_SOURCE_3	2º (~0,245)	2º	2º	2º	2º	UNÂNIME ✓
DAYS_EMPLOYED	3º (~0,085)	3º–4º	3º	3º	3º–4º	Consistente ✓
DAYS_BIRTH	4º (~0,075)	3º–4º	4º	4º	3º–4º	Consistente ✓
AMT_CREDIT	5º (~0,065)	marginal	5º	5º	5º	Moderado
AMT_ANNUITY	6º (~0,060)	marginal	6º	6º	6º	Moderado
DAYS_REGISTRATION	7º (~0,055)	marginal	7º	7º	7º	Fraco isolado
DAYS_ID_PUBLISH	8º (~0,050)	marginal	8º	8º	8º	Fraco isolado
DAYS_LAST_PHONE_CHANGE	9º (~0,045)	marginal	9º	9º	9º	Fraco isolado
AMT_INCOME_TOTAL	10º (~0,035)	NEGATIVO ⚠	Baixo	Baixo	Baixo	Fraco isolado ⚠

A Permutation Importance sobre F1-macro revelou que apenas `EXT_SOURCE_2` e `EXT_SOURCE_3` têm impacto positivo líquido na métrica geral. As 8 demais features apresentam contribuição marginal ou nula isoladamente — seu valor está em combinações. `AMT_INCOME_TOTAL` apresentou importância negativa na permutação, indicando que sua presença pode introduzir ruído. A principal alavanca para melhorar os três modelos é enriquecer o conjunto com mais variáveis de histórico de crédito externo.

3. Análise Crítica por Modelo

3.1 Random Forest

✓ Pontos Fortes	⚠ Limitações
Bagging com 200 árvores independentes: reduz variância — resistente a outliers e ruído sem ajustes adicionais.	Pipeline otimizado exigiu amostragem (50k registros) para viabilizar Colab gratuito. <code>max_depth=None</code> causava timeouts.

Melhor equilíbrio Recall/FP rate documentado: 0,537 de Recall com apenas 0,22 FP rate — mínimo de recusas indevidas.	Probabilidades mal calibradas: ECE=0,077 e Brier=0,1705 indicam superconfiança. Limita uso em pricing e provisionamento.
SHAP TreeExplainer: cálculo EXATO dos valores de Shapley — atende ao art. 20 da LGPD sem aproximações.	Pipeline não ponta a ponta: remoção de nulos, DAYS_EMPLOYED, VIF e seleção de features ficam FORA do sklearn Pipeline.
Único a atingir a meta completa (Recall $\geq$ 0,50, Balanced Acc $\geq$ 0,60, FP rate $\leq$ 0,30) no conjunto de teste.	RandomizedSearchCV com apenas 15 iterações sobre subconjunto — busca menos exaustiva que o XGBoost.

3.1.1 Hiperparâmetros — Random Forest

Hiperparâmetro	Valor	Justificativa Técnica
n_estimators	200	Abaixo de 200: underfitting. Acima: ganho $<$ 0,5 p.p. de Recall — custo computacional não justificado.
max_depth	12	Com 10 features, profundidade 12 evita overfitting sem restringir capacidade preditiva.
min_samples_split	10	Reduz ruído em nós com poucos clientes — divisões mais conservadoras.
min_samples_leaf	5	Impede folhas com 1–2 clientes — decisões muito específicas que não generalizam.
max_features	'sqrt'	Avalia $\sqrt{(n^\circ \text{ features})}$ por divisão. Aumenta diversidade entre árvores — fundamental para o bagging.
class_weight	'balanced'	Cada inadimplente contribui $\sim 11\times$ mais. Criticamente necessário com proporção 92/8.

3.1.2 RandomizedSearchCV — Random Forest

Configuração	Detalhe
n_iter	15 combinações aleatórias
cv	StratifiedKFold (3 folds) sobre subconjunto de 50k registros
Total de fits	45 fits — viabilizou execução no Colab gratuito
scoring	balanced_accuracy
Espaço de busca: n_estimators	randint(100, 300)
Espaço de busca: max_depth	[8, 10, 12] — sem None para evitar timeout

3.2 Regressão Logística

☑ Pontos Fortes	⚠ Limitações
MELHOR Recall documentado: 0,6433 — supera o RF em 10,6 p.p. Resultado que contraria a expectativa de modelos lineares.	FP rate 0,3233 — acima da meta $\leq$ 0,30. Recusa 32% dos bons pagadores contra 22% do RF: delta de 5.596 clientes no teste.
Coefficientes em log-odds auditáveis sem ferramentas auxiliares — atende LGPD art. 20 nativamente.	Restrição a relações lineares: interações EXT_SOURCE_2 $\times$ DAYS_BIRTH só capturadas se explicitamente incluídas.
Probabilidades estruturalmente calibradas via sigmoide — vantagem crítica para pricing e provisionamento.	Pipeline original colapsou com scoring='balanced_accuracy': Recall=0,000, Balanced Acc=0,500 — modelo inútil.

Convergência rápida: 250 fits em minutos — viabilidade computacional superior ao RF e ao XGBoost.

CalibratedClassifierCV colapsou detecção (sigmoid E isotonic) — padrão idêntico ao RF.

3.2.1 Hiperparâmetros — Regressão Logística

Hiperparâmetro	Valor	Justificativa Técnica
C	0,1	Regularização forte. C=0.1 reduz ruído de DAYS_REGISTRATION sem penalizar EXT_SOURCE_2/3, cujo sinal resiste à penalização L2.
penalty	'l2'	Ridge — encolhe todos os coeficientes sem zerá-los. Preferível a L1 porque todas as 10 features têm contribuição relevante.
solver	'lbfgs'	Algoritmo quasi-Newton eficiente para L2 em datasets de médio/grande porte. Converge mais rápido que 'saga' ou 'liblinear'.
max_iter	1000	Garante convergência mesmo com regularização forte.
class_weight	'balanced'	Cada inadimplente contribui ~11× mais para a função de perda.

3.2.2 Correção Crítica do Pipeline RL

Na versão anterior, `scoring='balanced_accuracy'` causou colapso completo (Recall=0,000, Balanced Accuracy=0,500). O otimizador encontrou C alto que enfraquecia a regularização, fazendo o modelo prever quase exclusivamente a classe 0.

Problema	Causa Raiz	Correção Aplicada
Recall=0,000 após RandomizedSearchCV	<code>scoring='balanced_accuracy'</code> — otimizador encontrou C alto que colapsa para classe 0	Substituído por <code>scoring='recall'</code> via <code>make_scorer(recall_score, pos_label=1)</code>
Dupla padronização dos dados	X_train_rl (já normalizado) passado ao Pipeline que normalizava novamente	Corrigido: X_train_raw (bruto) passado; StandardScaler interno ao Pipeline trabalha corretamente

Após correção: Recall=0,6427 — praticamente idêntico ao modelo base (delta=0,0006), confirmando que C=0.1 já estava próximo do ótimo.

3.3 XGBoost

☑ Pontos Fortes	⚠ Limitações
Boosting sequencial: cada nova árvore CORRIGE erros das anteriores, concentrando esforço nos inadimplentes — os mais difíceis.	Maior complexidade de otimização: 9 hiperparâmetros relevantes vs 5 do RF e 2 da RL — espaço exponencialmente maior.
scale_pos_weight integrado ao gradient boosting: penalização intrínseca, não externa — influencia ponderação durante cada divisão.	SMOTE + scale_pos_weight causou FP rate > 0,60 — colapso oposto. Confirma incompatibilidade com balanceamento nativo.
Regularização nativa L1 (reg_alpha) + L2 (reg_lambda) + gamma + min_child_weight + subsample — controle granular de overfitting.	Pipeline não ponta a ponta: mesmas limitações do RF para produção real.
Estratégia de busca mais rigorosa: curvas de aprendizado + GridSearchCV + RandomizedSearchCV com <code>scoring='recall'</code> desde o início.	Maior custo computacional médio — 75 fits Random + 90 fits Grid contra 45 fits do RF.

3.3.1 Hiperparâmetros — XGBoost

Hiperparâmetro	Valor	Justificativa Técnica
n_estimators	200	Curva de aprendizado confirmou convergência do CV Recall próximo a 200 árvores. Acima: ganho < 0,5 p.p.
max_depth	6	Identificado via curva de profundidade como pico de Balanced Accuracy. Profundidade ≤ 4: sub-ajuste. ≥ 8: leve overfitting.
learning_rate	0,10	Com 200 árvores, taxa 0.10 produz convergência adequada. Taxas menores exigiriam muito mais árvores.
scale_pos_weight	≈ 11,4	n(bons pagadores) / n(inadimplentes). Integrado diretamente na função de perda do gradient boosting.
eval_metric	'logloss'	Monitoramento interno durante treino — detecta overfitting nas curvas de aprendizado.
subsample	0,6–1,0	Espaço explorado no RandomizedSearchCV. Stochastic gradient boosting reduz correlação entre árvores.

3.3.2 Estratégia de Otimização — XGBoost (3 etapas)

Etap	Método	n_iter / configs	cv folds	Total fits	Resultado
1	Curva de aprendizado (n_estimators)	10 valores de n	StratifiedKFold(5)	50 fits	Convergência em ~200 confirmada
2	Curva de profundidade (max_depth)	7 valores [3–9]	StratifiedKFold(5)	35 fits	max_depth=6 identificado
3a	GridSearchCV (região identificada)	18 configs	StratifiedKFold(5)	90 fits	Região ótima refinada
3b	RandomizedSearchCV (busca ampla)	15 combinações	StratifiedKFold(5)	75 fits	Melhores hiperparâmetros finais

Essa triangulação (evidências empíricas + busca exaustiva regional + busca aleatória ampla) produz confiança superior nos hiperparâmetros finais. Nenhum dos outros dois modelos usou as três etapas simultaneamente.

4. Pipeline de Pesquisa e Análise de Dados

4.1 Sete Etapas do Pipeline

#	Etap	O que foi feito	Saída produzida
1	Coleta	Download via kagglehub. Leitura CSV 307.511×122. Verificação de tipos, nulos e distribuição TARGET.	DataFrame bruto df — 307.511 registros
2	EDA 1ª Parte	Análise estrutural, estatística descritiva por classe, pairplot, correlações de Pearson, VIF para multicolinearidade (AMT_GOODS_PRICE: VIF=39,51, ρ=0,99).	Diagnóstico: 92/8, 49 colunas a remover, multicolinearidade
3	Pré-processamento	Remoção 49 colunas. Imputação mediana. DAYS_EMPLOYED=365.243→mediana. OHE/OE + StandardScaler (RL). Remoção AMT_GOODS_PRICE.	73 colunas, sem nulos estruturais
4	EDA 2ª Parte	RF exploratório (n=100, depth=10, limiar 1%). Redução 122→10 features.	10 variáveis definitivas para todos os modelos

5	Modelagem	Split 60/20/20 estratificado. Modelo base. SMOTE (testado e descartado). Calibração (testada e descartada). RandomizedSearchCV.	model base + pipeline_otimizado (joblib)
6	Avaliação	Classification report, matrizes de confusão (abs e normalizada), curvas ROC e PR, Brier, ECE, LogLoss, Permutation Importance, SHAP.	Métricas finais — avaliação única sobre X_test
7	Inferência	predict/predict_proba em 6 perfis simulados. SHAP individual (Waterfall + Force Plot). Persistência joblib.	pipeline_otimizado.joblib pronto para reuso

4.2 Princípios de Design

Ausência de Data Leakage

O conjunto de teste foi separado ANTES de qualquer decisão de modelagem. O StandardScaler da RL foi ajustado exclusivamente sobre X_train. A correção do pipeline RL eliminou uma dupla padronização onde X_train_rl (já normalizado) era passado ao Pipeline que normalizava novamente — inflando artificialmente a aparência de robustez.

Reprodutibilidade Total

Todas as operações estocásticas usam random_state=42: split, RF exploratório, SMOTE, RandomizedSearchCV. O split estratificado (stratify=y) garante proporção 92/8 em todos os subconjuntos.

4.3 Estrutura Comparativa dos Pipelines sklearn

Componente	Random Forest	Regressão Logística	XGBoost
Imputer numérico	SimpleImputer (mediana)	SimpleImputer (mediana)	SimpleImputer (mediana)
Scaler	Não necessário	StandardScaler OBRIGATÓRIO	Não necessário
Encoder	OrdinalEncoder	OneHotEncoder (drop_first)	OrdinalEncoder
Classificador	RandomForestClassifier	LogisticRegression	XGBClassifier
Balanceamento	class_weight='balanced'	class_weight='balanced'	scale_pos_weight≈11,4
Scoring busca	balanced_accuracy	recall (pos_label=1) — CORRIGIDO	recall (pos_label=1)
Persistência	pipeline_credito_v2.joblib	pipeline_rl.joblib	pipeline_xgb.joblib

5. Análise de Vantagem Competitiva entre os Modelos

5.1 Síntese Comparativa Final — Quadro Mestre

Critério	Random Forest	Regressão Logística	XGBoost
Recall base (teste)	0,537	0,6433 ★	Esperado > 0,54
Balanced Accuracy base	0,657	0,6600 ★	Esperado ≥ 0,66
FP Rate base	0,22 ★	0,3233	—
Precision — Inadimplente	0,17	0,14	—
F1 — Inadimplente	0,26	0,23	—

Brier Score	0,1705	< 0,17 (melhor)	—
ECE	0,077	< 0,077 (melhor)	—
Acurácia Global	0,76	0,67	—
Calibração de probabilidades	Moderada	Boa — sigmoide nativa	Boa — nativa no boosting
Interpretabilidade LGPD	Alta — SHAP exato	Máxima — coef. diretos ★	Alta — SHAP exato
Custo computacional	Alto	Baixo ★	Médio-alto
Meta tripla atingida?	☑ SIM ★	✗ FP acima de 0,30	—
Pipeline corrigido?	Sim	Sim (após correção)	Sim — sem necessidade de correção
Estratégia de busca	15 iter, 45 fits	50 iter, 250 fits	3 etapas, 250 fits ★

5.2 O Modelo com Maior Vantagem Técnica: XGBoost

Analisando os três modelos para o objetivo central — maximizar detecção de inadimplentes em dataset severamente desbalanceado — o XGBoost apresenta a vantagem técnica mais consistente. A conclusão é sustentada por cinco razões:

#	Razão	Fundamentação Técnica Detalhada
1	Mecanismo de aprendizado mais adequado	O boosting sequencial foi concebido para exemplos difíceis de classificar — exatamente o que os 8% de inadimplentes representam. Cada nova árvore é construída para corrigir os erros das anteriores, com ênfase proporcional ao grau do erro. O bagging do RF dá peso igual a cada árvore independentemente dos erros anteriores. Na prática, o XGBoost concentra capacidade preditiva na fronteira de decisão onde o problema é mais difícil.
2	scale_pos_weight mais integrado	O class_weight='balanced' do RF e da RL é ajuste externo: multiplica perdas da classe minoritária por fator fixo antes do treino. O scale_pos_weight do XGBoost é incorporado à função de perda do gradient boosting — a penalização ocorre durante a construção sequencial, influenciando como interações entre features são ponderadas em cada divisão. Mais eficiente quando EXT_SOURCE_2 e DAYS_BIRTH têm relações não lineares entre si.
3	Regularização nativa mais flexível	O RF controla overfitting via restrições estruturais (max_depth, min_samples_leaf). A RL usa L2 pelo parâmetro C. O XGBoost oferece ambas simultaneamente: reg_alpha (L1), reg_lambda (L2), gamma (ganho mínimo para dividir nó), min_child_weight e subsample. Controle granular especialmente relevante com poucas features de alta importância relativa — EXT_SOURCE_2/3 respondem por ~50% da variância preditiva.
4	Estratégia de otimização mais rigorosa	O XGBoost foi o único modelo a combinar três métodos de evidência: curvas de aprendizado (validação empírica da convergência), GridSearchCV (cobertura exaustiva das regiões identificadas) e RandomizedSearchCV (exploração ampla). Além disso, usou scoring='recall' desde o início — sem necessitar de correção posterior como a RL precisou. Isso produz confiança superior nos hiperparâmetros finais.
5	Pipeline alinhado ao objetivo desde a concepção	A RL precisou de correção metodológica significativa (substituição da métrica de seleção, eliminação de dupla padronização). O XGBoost não teve esse problema porque a estratégia estava alinhada ao objetivo de negócio desde o início. Isso não diminui a qualidade final da RL corrigida — que entregou resultados equivalentes ao modelo base manual — mas indica maior maturidade metodológica.

5.3 Quando Cada Modelo é Preferível — Guia de Decisão

Contexto de Uso	Modelo Recomendado	Justificativa
Maximizar detecção (Recall)	XGBoost ★	Boosting + scale_pos_weight integrado + scoring='recall' desde o início
Minimizar recusas indevidas (FP rate)	Random Forest ★	FP rate = 0,22 vs 0,3233 da RL — única a atingir a meta tripla
Auditoria regulatória (LGPD art. 20)	Regressão Logística ★	Coeficientes em log-odds auditáveis sem ferramentas auxiliares
Pricing de risco com probabilidades	Regressão Logística ★	Sigmoide matematicamente bem definida; menor Brier Score documentado
Retreinamento frequente / ambiente limitado	Regressão Logística ★	250 fits em minutos; não depende de GPU
Produção: alta volumetria + explicação obrigatória	XGBoost ★	SHAP TreeExplainer exato + Recall superior + regularização granular
Balancear Recall e mínimo de falsos alarmes	Random Forest ★	Único com Recall ≥ 0,50 E FP rate ≤ 0,30 E Balanced Acc ≥ 0,60

5.4 Conclusão e Próximos Passos

O XGBoost é o modelo com maior vantagem técnica para o objetivo central. Seu mecanismo de aprendizado sequencial, a integração profunda do balanceamento via `scale_pos_weight`, a regularização nativa mais flexível e a estratégia de busca mais rigorosa justificam essa posição.

A Regressão Logística surpreendeu positivamente: Recall 0,6433 superando o RF em 10,6 p.p., com pipeline corrigido e funcional (Recall=0,6427). Sua contribuição principal é em auditoria, pricing e interpretabilidade regulatória.

O Random Forest entregou o ÚNICO modelo a atingir a meta tripla simultaneamente: Recall ≥ 0,50, Balanced Accuracy ≥ 0,60 e FP rate ≤ 0,30. É a escolha mais conservadora — adequada quando minimizar recusas indevidas é prioritário.

O achado transversal mais importante: `EXT_SOURCE_2` e `EXT_SOURCE_3` dominam o poder preditivo em todos os modelos e métodos de interpretabilidade. Com as 10 features atuais, todos os três estão próximos do teto de desempenho que os dados permitem. O principal caminho para melhorias não é otimizar hiperparâmetros — é enriquecer o conjunto de features com mais variáveis de histórico de crédito externo.