

Análise de Crédito e Predição de Inadimplência

Este relatório consolida os resultados finais dos três modelos desenvolvidos para o problema de predição de inadimplência em crédito ao consumidor (dataset Home Credit Default Risk / Kaggle), com base na versão mais recente dos três notebooks do projeto e nas correções solicitadas pelo orientador. Todos os valores numéricos apresentados foram extraídos diretamente dos outputs de execução do código (classification_report, matrizes de confusão e células de avaliação final), e não das células de texto narrativo — eliminando divergências entre o que foi descrito e o que foi efetivamente calculado.

1. Resumo

O projeto desenvolveu três modelos de classificação binária (Random Forest, Regressão Logística e XGBoost) para prever, antes da concessão do crédito, quais clientes apresentam maior probabilidade de inadimplência. A base contém 307.511 solicitações e 122 colunas originais, com desbalanceamento severo entre classes: 91,93% de bons pagadores e 8,07% de inadimplentes.

O projeto define a priori uma régua de avaliação com três critérios quantitativos simultâneos — Recall (Inadimplente) $\geq 0,50$, Balanced Accuracy $\geq 0,60$ e FP Rate $\leq 0,30$ — que um modelo precisa atender para ser considerado operacionalmente aceitável. Essa é a regra de decisão única adotada neste relatório (ver Seção 4).

Por esse motivo, o Random Forest (configuração base, com class_weight='balanced' e hiperparâmetros definidos manualmente) é o modelo recomendado para uso geral neste relatório. O XGBoost segue como alternativa de maior Recall para cenários em que a restrição de FP Rate $\leq 0,30$ não é obrigatória, e a Regressão Logística mantém sua vantagem em auditoria regulatória e calibração nativa de probabilidades.

1.1 Quadro-resumo da decisão

Modelo	Configuração	Recall $\geq 0,50$	Bal. Acc. $\geq 0,60$	FP Rate $\leq 0,30$	Aceitável?
Random Forest	Base (manual)	0,527	0,662	0,203	SIM
Random Forest	Otimizado (RandomizedSearchCV)	0,496	0,648	0,201	NÃO
Regressão Logística	Base (C=0,1)	0,643	0,660	0,323	NÃO
Regressão Logística	Otimizada (RandomizedSearchCV)	0,643	0,660	0,323	NÃO

Modelo	Configuração	Recall $\geq$ 0,50	Bal. Acc. $\geq$ 0,60	FP Rate $\leq$ 0,30	Aceitável?
XGBoost	Otimizado (RandomizedSearchCV, teste)	0,663 ✓	0,671 ✓	0,321 ✗	NÃO

2. Especificidades do Problema

3.1 Contexto e objetivo de negócio

O projeto aplica técnicas de aprendizado de máquina à predição de inadimplência em crédito ao consumidor, com base no dataset Home Credit Default Risk (Kaggle). O arquivo central, application_train.csv, contém 307.511 solicitações de crédito e 122 colunas originais, cobrindo informações demográficas, financeiras, comportamentais e de histórico de crédito.

O objetivo de negócio é identificar, antes da concessão do crédito, quais clientes têm maior probabilidade de inadimplência, permitindo recusa, ajuste de taxas, redução do valor concedido ou encaminhamento para análise manual.

3.2 Características do dataset

Dimensão	Detalhe
Volume total	307.511 solicitações × 122 colunas originais
Variável-alvo	TARGET: 0 = Bom Pagador (91,93%) / 1 = Inadimplente (8,07%)
Colunas removidas	49 colunas com mais de 40% de valores nulos
Dataset após limpeza	73 colunas; AMT_GOODS_PRICE removida por VIF = 39,51 e correlação de 0,99 com AMT_CREDIT
Features para modelagem	10 variáveis selecionadas via Random Forest exploratório (importância $\geq$ 1%)
Split de dados	60% treino (~184.506) / 20% validação (~61.502) / 20% teste (~61.503) — stratify=y, random_state=42

2.3 Desbalanceamento 92/8 — o desafio central

A proporção 92/8 entre bons pagadores e inadimplentes é a característica mais crítica do problema. Um modelo trivial que preveja sempre "bom pagador" atingiria 91,93% de acurácia sem identificar um único inadimplente — resultado tecnicamente impressionante e operacionalmente catastrófico.

Esse desbalanceamento determina as principais escolhas metodológicas do projeto: a métrica principal (Recall, em vez de Acurácia), a estratégia de compensação em cada modelo (class_weight ou scale_pos_weight), a rejeição do SMOTE após testes empíricos e a obrigatoriedade de validação cruzada estratificada.

2.4 As 10 features selecionadas

Feature	Tipo	Interpretação financeira
EXT_SOURCE_2	Contínua	Score externo normalizado — principal preditor em todos os modelos; consolida histórico de outras instituições.
EXT_SOURCE_3	Contínua	Segundo score externo. Junto com EXT_SOURCE_2, respondem por cerca de metade do poder preditivo total.
DAYS_BIRTH	Inteira	Idade em dias (negativo). Clientes jovens apresentam maior taxa de inadimplência.
DAYS_EMPLOYED	Inteira	Tempo de emprego em dias. Anomalia 365.243 (aposentados/desempregados) substituída pela mediana.
AMT_CREDIT	Contínua	Valor do crédito solicitado. Créditos muito altos em relação ao perfil sinalizam risco elevado.
AMT_ANNUITY	Contínua	Parcela mensal. Anuidades altas comprometem capacidade de pagamento.
AMT_INCOME_TOTAL	Contínua	Renda declarada. Preditor mais fraco isoladamente; efeito aparece combinado com AMT_CREDIT/AMT_ANNUITY.
DAYS_REGISTRATION	Inteira	Dias desde o registro cadastral. Proxy de estabilidade residencial.
DAYS_ID_PUBLISH	Inteira	Dias desde a emissão do documento de identidade. Sinal fraco, mas aditivo.
DAYS_LAST_PHONE_CHANGE	Inteira	Dias desde a última troca de telefone. Proxy de instabilidade comportamental.

2.5 Diferenças de pré-processamento entre os três modelos

Etapa	Random Forest	Regressão Logística	XGBoost
Remoção (>40% nulos)	Sim	Sim	Sim
Imputação numérica	Mediana	Mediana	Mediana
DAYS_EMPLOYED=365.243	Substituição mediana	Substituição mediana	Substituição mediana
Remoção AMT_GOODS_PRICE	Sim	Sim	Sim
Normalização	Não necessária	StandardScaler obrigatório	Não necessária
Balanceamento	class_weight='balanced'	class_weight='balanced'	scale_pos_weight ≈ 11,39

A normalização da Regressão Logística é obrigatória porque o gradiente descendente e a regularização L2 são sensíveis à escala. Sem o StandardScaler, AMT_CREDIT (ordem de centenas de milhares) e EXT_SOURCE_2/3 (entre 0 e 1) causariam convergência instável e coeficientes artificialmente distorcidos. Random Forest e XGBoost, baseados em divisões por limiar, são matematicamente insensíveis à escala das variáveis.

3. Métrica Principal e Régua de Avaliação

Esta seção formaliza a regra de decisão única adotada em todo o relatório (ver também Seção 2.5), respondendo a quatro perguntas: qual é a métrica principal, por que ela foi escolhida, qual o papel das demais métricas, e qual é o critério quantitativo de sucesso.

3.1 Métrica principal e métrica secundária

Métrica principal: Recall da classe Inadimplente (sensibilidade / True Positive Rate da classe positiva) — mede, dentre todos os clientes que de fato se tornaram inadimplentes, quantos o modelo conseguiu identificar antes da concessão do crédito.

Métrica secundária: Balanced Accuracy — média do recall das duas classes, robusta ao desbalanceamento 92/8.

3.2 Por que Recall e não Acurácia

- **Custo assimétrico dos erros:** em crédito, o custo de um Falso Negativo (inadimplente aprovado) é tipicamente 5 a 10 vezes maior que o custo de um Falso Positivo (bom pagador recusado) — o primeiro gera perda direta do principal, juros e custo de cobrança; o segundo, apenas perda de margem, com possibilidade de revisão futura do cliente.
- **Desbalanceamento severo:** um modelo trivial que prevê "bom pagador" para todos atinge ~92% de acurácia e ~0% de Recall — a Acurácia mascara a inutilidade prática do modelo, enquanto o Recall a expõe imediatamente.
- **Aderência regulatória e ética:** FNs geram exposição não monitorada de risco, com impacto em provisões contábeis e capital regulatório; FPs representam negação de crédito a clientes elegíveis, o que sob a LGPD (art. 20) pode ser objeto de revisão pelo titular dos dados — por isso Precision e FP Rate são mantidas como métricas de monitoramento, não descartadas.

3.3 Critério quantitativo de sucesso (régua única do projeto)

Patamar	Critério	Status no projeto
Mínimo aceitável	Recall (Inadimplente) $\geq 0,40$	Todos os modelos superam
Meta do projeto (régua de elegibilidade)	Recall $\geq 0,50$ E FP Rate $\leq 0,30$ E Balanced Accuracy $\geq 0,60$ — os três simultaneamente	Somente Random Forest Base

4. Resultados por Modelo

Todos os valores desta seção foram extraídos diretamente das células de código de avaliação final de cada notebook (classification_report, confusion_matrix e métricas derivadas), aplicadas uma única vez sobre o conjunto de teste, exceto onde explicitamente indicado como avaliação em validação. Onde havia divergência entre o texto narrativo do notebook e o resultado efetivo do código, prevaleceu o código (ver Seção 2.3).

4.1 Random Forest

4.1.1 Configuração base

Hiperparâmetros definidos manualmente: `n_estimators=200`, `max_depth=12`, `min_samples_split=10`, `min_samples_leaf=5`, `max_features='sqrt'`, `class_weight='balanced'`, `random_state=42`.

4.1.2 Configuração otimizada

Hiperparâmetros encontrados via `RandomizedSearchCV` (15 combinações × `StratifiedKFold` com 3 folds = 45 fits, `scoring='balanced_accuracy'`, sobre amostra de 50 mil registros do treino): `n_estimators=183`, `max_depth=10`, `max_features='log2'`, `min_samples_leaf=9`, `min_samples_split=3`. Melhor `balanced_accuracy` em validação cruzada: 0,6674.

4.1.3 Métricas no conjunto de teste

Métrica	Base (manual)	Otimizado (RandomizedSearchCV)	Meta
Recall — Inadimplente	0,527	0,496	≥ 0,50
Precision — Inadimplente	0,186	0,178	—
F1-score — Inadimplente	0,275	0,262	—
Recall — Bom Pagador (especificidade)	0,797	0,800	—
Balanced Accuracy	0,662	0,648	≥ 0,60
Acurácia Global	0,776	0,775	—
FP Rate (bons recusados)	0,203	0,201	≤ 0,30
Brier Score	—*	0,162	—
ECE	—*	0,091	—

Critério	Base	Otimizado
Recall ≥ 0,50	0,527	0,496
Balanced Accuracy ≥ 0,60	0,662	0,648
FP Rate ≤ 0,30	0,203	0,201
Operacionalmente aceitável?	SIM	NÃO

4.2 Regressão Logística

4.2.1 Configuração base

Hiperparâmetros definidos manualmente: `C=0,1`, `penalty='l2'`, `solver='lbfgs'`, `max_iter=1000`, `class_weight='balanced'`, `random_state=42`. Pré-processamento obrigatório: `StandardScaler` ajustado exclusivamente sobre `X_train`, evitando vazamento de informação do teste.

4.2.2 Configuração otimizada

Hiperparâmetros encontrados via RandomizedSearchCV (50 combinações × StratifiedKFold com 5 folds = 250 fits): C=9,833, penalty='l2', class_weight='balanced'. A busca otimiza F2-score da classe Inadimplente (beta=2, ponderando o Recall duas vezes mais que a Precision) — não balanced_accuracy, como ainda consta de forma desatualizada em um trecho de texto do notebook (divergência documentada na Seção 2.3). O F2-score evita tanto o colapso observado com balanced_accuracy em uma versão anterior do pipeline (Recall = 0,000) quanto o risco de um Recall=1 trivial que a otimização de Recall puro poderia produzir.

4.2.3 Métricas no conjunto de teste

Métrica	Base (C=0,1)	Otimizada (C=9,833)	Meta
Recall — Inadimplente	0,643	0,643	≥ 0,50
Precision — Inadimplente	0,149	0,150*	—
F1-score — Inadimplente	0,242	0,240*	—
Recall — Bom Pagador (especificidade)	0,677	0,677	—
Balanced Accuracy	0,660	0,660	≥ 0,60
Acurácia Global	0,674	0,670*	—
FP Rate (bons recusados)	0,323	0,323	≤ 0,30

Critério	Base	Otimizada
Recall ≥ 0,50	0,643 ✓	0,643 ✓
Balanced Accuracy ≥ 0,60	0,660 ✓	0,660 ✓
FP Rate ≤ 0,30	0,323 ✗	0,323 ✗
Operacionalmente aceitável?	NÃO	NÃO

A busca de hiperparâmetros praticamente não alterou o resultado (diferenças da ordem de milésimos): C=0,1 já era próxima do ótimo para este dataset, e o aumento de C para 9,833 (regularização muito mais fraca) não trouxe ganho líquido em Recall nem reduziu o FP Rate o suficiente para cruzar a meta de 30%. Em ambas as configurações, a Regressão Logística viola a meta de FP Rate e por isso não é operacionalmente aceitável pela régua do projeto — mesmo apresentando o maior Recall isolado entre os três modelos.

4.3 XGBoost

4.3.1 Configuração baseline

Hiperparâmetros conservadores, alinhados ao Random Forest para comparabilidade: n_estimators=200, max_depth=6, learning_rate=0,10, scale_pos_weight≈11,39 (calculado como n_negativos/n_positivos no treino), eval_metric='logloss'. Avaliado no conjunto de validação.

4.3.2 Configuração otimizada

O notebook realiza três etapas de busca: (1) curvas de aprendizado para `n_estimators` e `max_depth`, validando empiricamente `n_estimators`≈200 e `max_depth`=6 como região de equilíbrio; (2) `GridSearchCV` (18 combinações × 5 folds = 90 fits, `scoring`='recall'); (3) `RandomizedSearchCV` (15 combinações × 5 folds = 75 fits, espaço de 9 hiperparâmetros, `scoring`='recall'). O modelo final usa os hiperparâmetros do `RandomizedSearchCV` — a busca com maior cobertura do espaço de parâmetros: `n_estimators`=180, `max_depth`=5, `learning_rate`=0,011, `subsample`=0,842, `colsample_bytree`=0,909, `min_child_weight`=3, `gamma`=0,099, `reg_alpha`=0,711, `reg_lambda`=4,056, `scale_pos_weight`≈11,39.

4.3.3 Métricas

Métrica	Baseline (validação)	Otimizado (RandomizedSearchCV, teste)	Meta
Recall — Inadimplente	0,614	0,663	≥ 0,50
Precision — Inadimplente	0,17	0,15	—
Balanced Accuracy	0,671	0,671	≥ 0,60
Acurácia Global	0,72	0,68	—
FP Rate (bons recusados)	0,273	0,321	≤ 0,30
Brier Score	0,185	0,210	—

Critério	Otimizado
Recall ≥ 0,50	0,663 ✓
Balanced Accuracy ≥ 0,60	0,671 ✓
FP Rate ≤ 0,30	0,321 ✗
Operacionalmente aceitável?	NÃO

O XGBoost otimizado entrega o maior Recall (0,663) e a maior Balanced Accuracy (0,671) dos três modelos no conjunto de teste, confirmando a vantagem teórica do boosting sequencial para a classe minoritária. No entanto, viola a meta de FP Rate (0,321 > 0,30), recusando indevidamente cerca de 32% dos bons pagadores acima do Random Forest (20,3%) e mesmo da Regressão Logística (32,3%, neste caso equivalente). Pela régua do projeto, essa configuração não é operacionalmente aceitável.

É importante notar que o SMOTE combinado ao XGBoost sem `scale_pos_weight` elevou o Recall para aproximadamente 0,89, mas com FP Rate acima de 0,60, uma violação ainda mais severa da meta, confirmando o mesmo padrão de colapso observado nos demais modelos (ver Seção 6).

5. Quadro Mestre Comparativo (Configurações Otimizadas)

Conforme solicitado, esta tabela consolida as configurações otimizadas de cada notebook (RandomizedSearchCV), todas avaliadas uma única vez sobre o conjunto de teste. Como discutido na Seção 5.1.3, o Random Forest otimizado não é a configuração recomendada — por isso a tabela inclui também o Random Forest Base, que é a configuração efetivamente recomendada por este relatório, marcada em destaque.

Métrica	RF Base (recomendado)	RF Otimizado	RL Otimizada	XGB Otimizado
Recall — Inadimplente ↑	0,527	0,496	0,643	0,663
Precision — Inadimplente	0,186	0,178	0,150	0,15
Balanced Accuracy ↑	0,662	0,648	0,660	0,671
Acurácia Global	0,776	0,775	0,670	0,68
FP Rate (bons recusados) ↓	0,203	0,201	0,323	0,321
Meta Recall $\geq 0,50$	☑	✗	☑	☑
Meta Balanced Acc $\geq 0,60$	☑	☑	☑	☑
Meta FP Rate $\leq 0,30$	☑	☑	✗	✗
Operacionalmente aceitável	SIM	NÃO	NÃO	NÃO

6. Por que o Random Forest é o Modelo Recomendado

Esta seção desenvolve, em detalhe, a explicação solicitada sobre os três critérios da régua de avaliação e por que o Random Forest (configuração base) é o único modelo do projeto, dentre as seis configurações testadas (RF base, RF otimizado, RL base, RL otimizada, XGB baseline, XGB otimizado avaliados em teste), que os atende simultaneamente.

6.1 Critério 1 — Recall (Inadimplente) $\geq 0,50$

Este critério garante que o modelo capture, no mínimo, metade dos clientes que de fato se tornarão inadimplentes — o patamar mínimo para que o modelo tenha utilidade prática de proteção de carteira, já que o erro de Falso Negativo é o mais caro do problema (perda direta do principal).

Random Forest Base: 0,527 — ATENDE. O modelo captura 52,7% dos inadimplentes reais do conjunto de teste, superando a meta em 2,7 pontos percentuais.

Todos os demais modelos também atendem a este critério isoladamente (RL: 0,643; XGBoost: 0,663) — o Recall não é, portanto, o critério que distingue o Random Forest dos demais. A diferenciação ocorre nos dois critérios seguintes.

6.2 Critério 2 — Balanced Accuracy $\geq 0,60$

Este critério garante que o modelo não esteja apenas "jogando tudo para a classe minoritária" para inflar o Recall artificialmente — ele pondera igualmente o desempenho nas duas classes, funcionando como um freio de sanidade contra modelos degenerados (como o caso do SMOTE com XGBoost sem `scale_pos_weight`, que elevou o Recall para 0,89 às custas de uma Balanced Accuracy/FP Rate inaceitáveis).

Random Forest Base: 0,662 — ATENDE. Folga de 6,2 pontos percentuais acima do mínimo de 0,60.

6.3 Critério 3 — FP Rate $\leq 0,30$ (o critério decisivo)

Este é o critério que efetivamente separa o Random Forest dos demais modelos. Ele limita a fração de bons pagadores recusados indevidamente — o custo operacional e reputacional da estratégia de detecção. Um modelo pode ter Recall altíssimo simplesmente recusando quase todo mundo; o FP Rate impede que essa estratégia degenerada seja aceita como solução.

Modelo (configuração avaliada em teste)	FP Rate	Meta $\leq 0,30$	Bons pagadores recusados indevidamente (de 56.538)
Random Forest Base	0,203	☑	≈ 11.473
Random Forest Otimizado	0,201	☑	≈ 11.357
Regressão Logística (base/otim.)	0,323	✗	≈ 18.279
XGBoost Otimizado	0,321	✗	≈ 18.143

A Regressão Logística e o XGBoost recusam indevidamente cerca de 60% a mais de bons pagadores que o Random Forest (≈18.200 contra ≈11.400, em uma base de teste com 56.538 bons pagadores reais) para obter um ganho de Recall de 12 a 14 pontos percentuais. Esse é exatamente o trade-off que a meta tripla foi desenhada para regular: o projeto define explicitamente que esse nível de recusa indevida (acima de 30%) não é aceitável, independentemente do ganho de Recall que ele compre.

6.4 Síntese: a interseção dos três critérios

Random Forest Base é o único ponto do espaço de modelos testados que cai simultaneamente dentro das três regiões aceitáveis — Recall $\geq 0,50$, Balanced Accuracy $\geq 0,60$ e FP Rate $\leq 0,30$. Isso não significa que seja o melhor modelo em todas as métricas isoladas (não é o de maior Recall, nem o de maior Balanced Accuracy), mas é o único que respeita integralmente a régua de elegibilidade definida a priori pelo projeto — e por isso, pela regra de decisão de Nível 1 (Seção 4.3), é o modelo recomendado para uso geral.

Por que isso importa metodologicamente

Definir a régua de aceitação antes de ver os resultados (a priori) é o que torna esta conclusão defensável e não um exercício de "escolher a métrica que favorece o resultado desejado depois do fato". A régua de três critérios foi fixada na Seção 4 deste relatório, replicada do critério já estabelecido nos três notebooks do projeto, e aplicada de forma idêntica e sem exceção a todas as seis configurações avaliadas.

7. Conclusão

7.1 Achados principais

1. O dataset apresenta desbalanceamento severo (92% bons pagadores / 8% inadimplentes), o que torna a Acurácia uma métrica inadequada e justifica o uso de Recall como métrica principal, com Balanced Accuracy e FP Rate como metas complementares de elegibilidade.
2. Random Forest (configuração base) é o único modelo do projeto — entre seis configurações avaliadas em teste — que atende simultaneamente aos três critérios da meta do projeto: $\text{Recall} = 0,527 \geq 0,50$; $\text{Balanced Accuracy} = 0,662 \geq 0,60$; $\text{FP Rate} = 0,203 \leq 0,30$.
3. A versão otimizada do próprio Random Forest (RandomizedSearchCV, `scoring='balanced_accuracy'`) reduz o Recall abaixo da meta (0,496), evidenciando que otimizar uma métrica secundária não garante atender à métrica principal, recomenda-se reexecutar essa busca com `scoring` alinhado ao Recall.
4. Regressão Logística entrega o maior Recall isolado entre as configurações base (0,643) e mantém vantagens estruturais em interpretabilidade (coeficientes em log-odds) e calibração nativa de probabilidades, mas viola a meta de FP Rate (0,323) tanto na versão base quanto na otimizada.
5. XGBoost otimizado entrega o melhor desempenho isolado em Recall (0,663) e Balanced Accuracy (0,671) do projeto, mas também viola a meta de FP Rate (0,321) quando avaliado corretamente no conjunto de teste.
6. SMOTE piorou o desempenho nos três modelos de forma consistente; a calibração padrão (CalibratedClassifierCV) colapsou a detecção da classe minoritária no Random Forest e na Regressão Logística — ambas as técnicas foram corretamente descartadas pelos notebooks.
7. EXT_SOURCE_2 e EXT_SOURCE_3 dominam o poder preditivo em todos os modelos e métodos de interpretabilidade (Gini, Permutation Importance, SHAP, coeficientes), respondendo por cerca de metade do sinal preditivo total.
8. Os pipelines dos três notebooks já encapsulam, como transformadores customizados de scikit-learn, as etapas de limpeza, tratamento de anomalias, remoção de colinearidade e seleção de features — recebendo o DataFrame bruto e produzindo a predição final em uma única chamada `.fit()/predict()`.

10.2 Recomendação final

Recomenda-se o Random Forest, na configuração base (`n_estimators=200`, `max_depth=12`, `min_samples_split=10`, `min_samples_leaf=5`, `class_weight='balanced'`), encapsulado no pipeline

ponta a ponta, como modelo de uso geral da instituição — por ser o único que atende integralmente à régua de aceitação definida a priori pelo projeto. XGBoost e Regressão Logística permanecem como alternativas válidas para os cenários específicos descritos na Seção 9, desde que a instituição assuma conscientemente o FP Rate acima de 30% que essas configurações implicam.